

Além da Acurácia: Modelagem Matemática Abrangente para Recomendação de Preços em Seguro Saúde, Orientada por Identificação de Sistemas e Comparada a um Workflow Gerado por IA

Renan de Abreu Caetano

Especialista em Ciência de Dados, IGTI / XP Educação. Engenheiro Eletricista com ênfase em Automação e Controle, Centro Universitário do Leste de Minas Gerais (Unileste).

E-mail: renanacaetano@gmail.com

Resumo

Este artigo apresenta um estudo aplicado de modelagem matemática para recomendação de preços em seguro saúde. O trabalho parte de um conjunto público do Kaggle com 1.338 registros reais anonimizados de clientes de uma operadora de plano de saúde e separa duas decisões frequentemente confundidas em projetos de precificação: a definição de prêmio inicial para novos clientes e o reajuste de prêmios para clientes atuais. Foram comparados K-Means, Regressão Linear, famílias candidatas de modelos estáticos não lineares orientadas por princípios de Identificação de Sistemas, Kernel Ridge e um Random Forest gerado por um workflow de IA. No holdout de 268 clientes, o Random Forest obteve melhor acurácia preditiva ($RMSE = R\$ 647,89$; $R^2 = 0,797$), enquanto o Kernel Ridge foi a melhor alternativa selecionada pelo protocolo formal antes do benchmark de IA ($RMSE = R\$ 753,18$; $R^2 = 0,726$). Para clientes atuais, demonstrou-se que a previsão de despesas não deve ser aplicada diretamente como política de reajuste: o problema passa a ser controlar churn e preservar margem. A contribuição central é um framework que conecta modelagem, validação, precificação e churn, mostrando que maior acurácia não substitui governança e decisão econômica.

Palavras-chave: seguro saúde; precificação; Identificação de Sistemas; aprendizado de máquina; churn; Random Forest; Kernel Ridge.

Abstract

This paper presents an applied mathematical modeling study for health insurance pricing recommendation. Using a public Kaggle dataset with 1,338 anonymized real customer records, the study separates two decisions that are often mixed in pricing projects: initial premium setting for new customers and premium readjustment for current customers. K-Means, Linear Regression, candidate static nonlinear models guided by System Identification principles, Kernel Ridge, and an AI-generated Random Forest workflow were compared. On the 268-customer holdout, Random Forest achieved the best predictive accuracy, while Kernel Ridge was the strongest formally selected alternative before the AI benchmark. For current customers, the study shows that expense prediction models should not be directly reused as readjustment policies: the decision becomes churn-constrained premium adjustment. The main contribution is a reproducible framework connecting modeling, validation, pricing and churn.

Keywords: health insurance; pricing; System Identification; machine learning; churn; Random Forest; Kernel Ridge.

1 Introdução

A precificação de seguro saúde é um problema simultaneamente estatístico, econômico e gerencial. A empresa precisa estimar o custo esperado de cada cliente, definir um prêmio compatível com a margem desejada e evitar que reajustes excessivos provoquem cancelamento. Em projetos de dados, essas três decisões costumam ser comprimidas em uma única pergunta: qual modelo prevê melhor a despesa médica? Essa pergunta é necessária, mas insuficiente. Um modelo com menor erro médio pode produzir recomendações de preço que elevam churn, reduzem lucro ou dificultam a justificativa regulatória.

Este trabalho propõe uma formulação mais abrangente. Primeiro, trata-se a entrada de novos clientes como um problema de previsão de despesas. Segundo, trata-se a carteira atual como um problema de reajuste sob restrição de churn, pois para clientes existentes já se observam prêmio vigente e despesa realizada. Terceiro, compara-se uma modelagem orientada por princípios de Identificação de Sistemas com um workflow gerado por IA, aproximando o estudo de uma situação real em que um gestor poderia solicitar a um sistema de IA a criação automática de um modelo de previsão.

A contribuição do artigo é mostrar que a discussão não deve terminar em RMSE, MAE ou R^2 . Tais métricas indicam qualidade preditiva, mas a recomendação de preço exige também uma função de transformação da previsão em prêmio, uma hipótese de churn, uma política para clientes deficitários e uma análise de auditabilidade. Por isso, o estudo organiza o problema como uma cadeia de decisão: dados, escolha estrutural, validação, preço, churn e lucro.

2 Trabalhos relacionados e fundamentação

2.1 Precificação com aprendizado de máquina explicável

Trabalhos recentes em seguro saúde mostram interesse crescente por aprendizado de máquina explicável, isto é, modelos preditivos acompanhados de técnicas que ajudam a interpretar os determinantes de custo ou prêmio. Orji e Ukwandu (2024) comparam Random Forest, Gradient Boosting e XGBoost para previsão de custos médicos, utilizando SHAP e ICE para interpretar variáveis relevantes. Kapse et al. (2025) também abordam customização de prêmios com aprendizado de máquina e IA explicável. Em escala industrial, Kshirsagar et al. (2021) reportam modelos interpretáveis para precificação transparente de planos de saúde, com desempenho superior ao modelo atuarial interno da seguradora avaliada.

O presente trabalho dialoga com essa literatura, mas enfatiza uma diferença: a previsão de despesa é tratada como etapa intermediária de uma recomendação de preço. Portanto, além de acurácia e interpretabilidade, são avaliados efeitos de churn e lucro, distinguindo novos clientes de clientes atuais.

2.2 Identificação de Sistemas como guia de modelagem

A Identificação de Sistemas, conforme Ljung (1999) e Aguirre (2014), oferece uma disciplina formal para escolher a estrutura de um modelo a partir do comportamento dos dados, em vez de selecionar algoritmos de modo informal. É importante esclarecer que essa literatura não se restringe a sistemas dinâmicos: embora o campo tenha se desenvolvido na engenharia de controle, Aguirre (2014) trata explicitamente modelos estáticos não lineares — polinomiais, racionais, splines, redes neurais, modelos nebulosos e métodos baseados em kernel —, e a própria árvore de decisão da disciplina bifurca, logo no início, entre o caso dinâmico e o caso estático. Este estudo apoia-se justamente no ramo estático dessa árvore, que é a parte formalmente adequada do arcabouço para o problema analisado.

A metodologia de seleção de modelos de Ljung e Aguirre pode ser resumida em quatro passos. Primeiro, classificar o sistema como dinâmico ou estático, observando se há dependência temporal entre as observações. Segundo, testar se uma estrutura linear é suficiente, por exemplo comparando o R^2 de um modelo linear com o de um polinômio de grau dois. Terceiro, respeitar o princípio da parcimônia, preferindo o modelo mais simples compatível com os dados — Ljung (1999) sugere, como regra prática, ao menos cinco observações por parâmetro estimado. Quarto, validar o desempenho fora da amostra, em dados não utilizados na estimação. O critério final não é apenas o menor erro de ajuste, mas a combinação entre aderência aos dados, simplicidade estrutural e capacidade de generalização.

Este trabalho aplicou exatamente essa sequência. O conjunto analisado é transversal — cada linha representa um cliente em um instante, sem memória temporal explícita —, de modo que o problema é estático por construção. Em seguida, testou-se a suficiência de relações lineares, compararam-se famílias candidatas de modelos estáticos e validou-se o desempenho no holdout de 268 clientes. O Kernel Ridge não é apresentado como recomendação direta de Ljung ou Aguirre; ele entra como candidato coerente dentro da etapa de modelos estáticos não lineares, por representar uma superfície de regressão flexível via kernel RBF e regularização L2.

2.3 IA generativa e workflows de ciência de dados

O uso de modelos de linguagem para automatizar fluxos de análise de dados tornou-se uma frente ativa de pesquisa. Gu et al. (2024) revisam o uso de LLMs em workflows de aprendizado de máquina, incluindo engenharia de atributos, seleção de modelos, otimização de hiperparâmetros e avaliação. Jansen et al. (2025) mostram que LLMs podem gerar pipelines de análise, mas também que a complexidade da tarefa reduz a confiabilidade do código executável. Zeng et al. (2025) reforçam que, em ciência de dados, não basta observar o resultado; é preciso avaliar a reprodutibilidade e o plano lógico do workflow.

Neste estudo, o workflow gerado por IA é tratado como benchmark externo. Ele representa a resposta que um gestor sem formação estatística poderia obter ao pedir, em linguagem natural, um método para prever despesas de futuros clientes. Essa comparação é relevante porque testa não apenas acurácia, mas também o que a IA não entrega automaticamente: diagnóstico estatístico, separação de problemas de negócio, governança e política para clientes atuais.

2.4 Reajuste de prêmio e churn

A relação entre aumento de prêmio e cancelamento é central na saúde suplementar. Souza et al. (2025) estudam, por regressão descontínua, o efeito de reajustes por faixa etária sobre cancelamento e troca de planos no Brasil, mostrando que o preço é um determinante relevante da saída de beneficiários. Esse resultado justifica incorporar churn à recomendação de preço. No presente projeto, a função de churn implementada no notebook é uma parametrização operacional inspirada nessa lógica de descontinuidade; por isso, os resultados devem ser interpretados como simulação decisória, não como estimação causal original.

3 Materiais e métodos

3.1 Dados

A base utilizada é pública, obtida no Kaggle, e contém 1.338 registros reais anonimizados de clientes de uma operadora de plano de saúde. A identidade da operadora não é informada e deve permanecer confidencial. As variáveis disponíveis são idade, gênero, índice de massa corporal, número de filhos, elegibilidade a desconto, região, despesas médicas e prêmio cobrado.

Variável	Significado	Tipo	Uso no estudo
age	idade do cliente	numérica	perfil de risco e predição de despesas
gender	gênero	categórica	codificação para modelos supervisionados
bmi	índice de massa corporal	numérica	risco de saúde
children	número de filhos	discreta	estrutura familiar e uso esperado
discount_eligibility	elegibilidade a desconto	binária	segmentação e composição do perfil
region	região (localidade)	categórica	controle regional
expenses	despesas médicas	numérica	alvo de previsão
premium	prêmio (mensalidade cobrada)	numérica	base de reajuste para clientes atuais

Tabela 1 - Variáveis utilizadas no estudo.

Ao longo do texto, o termo prêmio designa a mensalidade cobrada do cliente; os dois termos são usados como sinônimos. A base foi dividida aleatoriamente em duas partes, com `random_state = 1` para garantir a reprodutibilidade do experimento: 80% dos registros (1.070 clientes) formaram o conjunto de treinamento, usado para estimar os modelos, e os 20% restantes (268 clientes) constituíram o conjunto de teste, mantido completamente separado durante todo o ajuste. É esse conjunto de 20% que, ao longo do artigo, é designado holdout de 268 clientes: ele só é utilizado na avaliação final, de modo que todas as métricas reportadas medem desempenho fora da amostra. A Figura 1 mostra que a variável de despesas apresenta cauda à direita, com assimetria positiva de 0,749. Esse ponto é importante porque modelos lineares simples podem ser afetados por observações de maior despesa e por relações não lineares não especificadas.




Figura 1 - Distribuição das despesas médicas observadas na base pública.

3.2 Modelos avaliados

Foram avaliadas abordagens de segmentação, regressão e aprendizado de máquina. O K-Means foi usado como baseline de segmentação, atribuindo a cada cliente a despesa média do cluster; o número de grupos foi fixado em quatro, definido pelo método do cotovelo. A Regressão Linear funcionou como baseline interpretável. Em seguida, foram testadas famílias candidatas de modelos estáticos lineares e não lineares: Regressão Polinomial grau 2, Ridge, Lasso, Spline Natural, MLP e Kernel Ridge. Por fim, um Random Forest gerado por workflow de IA foi comparado como benchmark externo; esse workflow foi produzido por vibe coding na ferramenta Claude Code (Anthropic), com o modelo Opus 4.7, e é detalhado na Seção 4.5. Para que a comparação fosse justa, o workflow de IA recebeu exatamente o mesmo conjunto de treinamento (os 80% dos clientes) usado pelos demais modelos e foi avaliado no mesmo holdout de 268 clientes (os 20% de teste).

Família	Função no estudo	Observação metodológica
K-Means (Clusterização)	segmentação	não otimiza erro de regressão; prediz média do grupo
Regressão Linear	baseline explicável	modelo aditivo e linear
Polinomial grau 2	teste de curvatura	avaliou se termos quadráticos agregavam valor
Ridge/Lasso	regularização	controle de instabilidade e seleção de termos
Spline Natural	não linear suave	flexibilidade com estrutura interpretável
MLP	não linear flexível	rede neural feedforward
Kernel Ridge	não linear regularizado	kernel RBF com penalização L2
Random Forest (IA)	benchmark externo	escolhido por workflow gerado por IA

Tabela 2 - Famílias de modelos avaliadas.

3.3 Formulação matemática

Na Regressão Linear, as despesas são aproximadas por uma combinação aditiva das variáveis explicativas:

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i$$

No K-Means, cada cliente recebe como previsão a despesa média do cluster ao qual foi atribuído:

$$\hat{y}_i = \bar{y}_{c_i}$$

No Kernel Ridge com kernel RBF, a previsão é uma soma ponderada de similaridades entre o cliente analisado e os pontos de treino:

$$\hat{y}(x) = \sum_i \alpha_i \exp(-\gamma \|x - x_i\|^2), \quad \alpha = (K + \lambda I)^{-1} y$$

No Random Forest, a previsão de regressão é a média das previsões produzidas pelas B árvores do ensemble:

$$\hat{y}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

A transformação de despesa estimada em preço utilizou margem desejada de 25%:

$$P_i = \frac{\hat{y}_i}{1-m}, \quad m = 0,25$$

A função operacional de churn usada no notebook considera o aumento percentual do prêmio em relação ao prêmio atual:

$$c(\Delta_i) = \alpha + \beta_1 x_i + \beta_2 I(x_i \geq 0,20) + \beta_3 (x_i - 0,20) I(x_i \geq 0,20)$$

em que $x_i = \Delta_i/100$, $\alpha = 0,05$, $\beta_1 = 1$, $\beta_2 = 0,15$ e $\beta_3 = 1,5$. A função é truncada ao intervalo $[0, 1]$.

Por fim, escrevendo a Regressão Linear com as variáveis específicas da base de dados, a estrutura estimada para a despesa de cada cliente assume a forma:

$$\text{despesas} = \beta_0 + \beta_1 \text{age} + \beta_2 \text{bmi} + \beta_3 \text{children} + \beta_4 \text{gender} + \beta_5 \text{discount} + \beta_6 \text{region} + \varepsilon$$

em que age, bmi e children entram diretamente como variáveis numéricas, enquanto gender, discount (elegibilidade a desconto) e region são variáveis categóricas codificadas como variáveis binárias (dummies); region, por possuir quatro categorias, expande-se em três variáveis binárias. O termo ε representa o erro aleatório. As demais famílias não lineares operam sobre o mesmo vetor de variáveis, alterando apenas a forma funcional que relaciona essas variáveis às despesas.

4 Resultados

4.1 Variável-alvo e previsões por cliente

Antes da seleção formal, convém esclarecer o que cada modelo efetivamente estimou. Em todos os casos — K-Means, Regressão Linear, Kernel Ridge e Random Forest — a variável-alvo é a mesma: a despesa médica (expenses) de cada cliente. A Tabela 3 ilustra, para uma amostra de clientes do holdout, a despesa real ao lado da despesa prevista por cada modelo. São exibidas apenas algumas linhas; as métricas reportadas nas seções seguintes são calculadas sobre os 268 clientes do holdout.

Cliente	Despesa real	K-Means	Reg. Linear	Kernel Ridge	Random Forest
1	R\$ 1.653,18	R\$ 1.893,97	R\$ 1.855,39	R\$ 1.835,42	R\$ 1.900,37
2	R\$ 5.589,00	R\$ 4.713,26	R\$ 4.549,25	R\$ 4.859,94	R\$ 4.634,04
3	R\$ 5.159,52	R\$ 4.713,26	R\$ 4.495,62	R\$ 4.979,05	R\$ 4.828,12
4	R\$ 3.315,35	R\$ 2.097,74	R\$ 3.035,32	R\$ 2.516,18	R\$ 2.281,50
5	R\$ 1.413,54	R\$ 1.893,97	R\$ 1.559,28	R\$ 1.711,26	R\$ 1.834,92
6	R\$ 2.569,80	R\$ 2.618,75	R\$ 1.860,84	R\$ 1.746,13	R\$ 2.039,84
7	R\$ 2.393,93	R\$ 2.097,74	R\$ 3.524,56	R\$ 3.145,19	R\$ 2.220,81
8	R\$ 5.548,98	R\$ 4.713,26	R\$ 4.333,43	R\$ 4.708,59	R\$ 4.486,73

Tabela 3 - Despesa real e despesa estimada por cada modelo para uma amostra de 8 dos 268 clientes do holdout.

A leitura individual da Tabela 3 mostra que, para a maioria dos clientes, os quatro modelos chegam a valores próximos entre si — é o caso do Cliente 1, cujas quatro estimativas se concentram em uma faixa estreita em torno da despesa real. A divergência aparece nos casos de despesa atípica. Entende-se por despesa atípica a do cliente cujo gasto observado é difícil de explicar a partir do seu perfil de risco — idade, índice de massa corporal e número de filhos: por exemplo, um cliente jovem e de baixo risco aparente que ainda assim registra despesa elevada, ou o oposto. Nesses pontos, cada modelo reage de forma distinta — o K-Means atribui a média do cluster, ao passo que modelos flexíveis como o Kernel Ridge e o Random Forest ajustam a superfície de previsão localmente —, e as estimativas se afastam umas das outras.

Essa divergência é visível na própria Tabela 3. No Cliente 4, a despesa real é de R\$ 3.315,35, mas as estimativas dos quatro modelos se espalham entre R\$ 2.097,74 e R\$ 3.035,32; no Cliente 7, a despesa real é de R\$ 2.393,93 e as estimativas vão de R\$ 2.097,74 a R\$ 3.524,56 — uma diferença de mais de R\$ 1.426,82 entre o menor e o maior valor previsto. Esses dois clientes contrastam com o Cliente 1, em que a maior e a menor estimativa diferem em poucas dezenas de reais. É exatamente nesses casos atípicos que a escolha do modelo passa a importar, pois é onde os erros individuais se concentram. Essa visão por cliente torna mais transparente a Tabela 4, que sintetiza o desempenho de cada modelo sobre toda a base de holdout.

4.2 Seleção formal de modelos

Na etapa interna de seleção, o Kernel Ridge obteve o melhor desempenho entre as famílias candidatas avaliadas antes do benchmark de IA. A Tabela 4 apresenta os resultados no split interno do conjunto de treino, com validação 80/20 e validação cruzada quando aplicável.

Modelo	R ² treino	R ² validação	RMSE val.	MAE val.	CV R ²
Kernel Ridge	0,76	0,78	R\$ 650,53	R\$ 498,95	0,7161 +/- 0,0472
Spline Natural	0,70	0,73	R\$ 712,24	R\$ 563,41	0,6869 +/- 0,0334
MLP	0,68	0,71	R\$ 742,52	R\$ 550,83	0,6194 +/- 0,0521
Polinomial grau 2	0,69	0,69	R\$ 761,45	R\$ 580,64	-
Regressão Linear	0,61	0,68	R\$ 776,10	R\$ 604,86	0,6020 +/- 0,0455
Ridge	0,61	0,68	R\$ 777,15	R\$ 604,96	0,6025 +/- 0,0466
Lasso	0,61	0,68	R\$ 778,35	R\$ 604,96	0,6037 +/- 0,0471

Tabela 4 - Seleção interna de modelos estáticos candidatos.

O resultado indica que termos polinomiais não foram suficientes para superar o Kernel Ridge e que modelos lineares regularizados permaneceram próximos do baseline linear. Como Spline Natural e MLP apresentaram desempenho próximo ao do Kernel Ridge, a escolha foi confirmada por testes formais de Diebold-Mariano (Diebold e Mariano, 1995) — que comparam a acurácia preditiva entre modelos não aninhados — e pela maior estabilidade do Kernel Ridge na validação cruzada; a etapa formal incluiu ainda análise de resíduos (homoscedasticidade e normalidade). Assim, a seleção formal favoreceu uma estrutura não linear regularizada, coerente com a hipótese de que interações locais e suavidade no espaço de atributos são relevantes para despesas médicas.

4.3 Desempenho no holdout de 268 clientes

Após a seleção, o Kernel Ridge foi reestimado no conjunto completo de treino e avaliado no holdout de 268 clientes. Em seguida, o Random Forest gerado pelo workflow de IA foi avaliado na mesma base. A Tabela 5 mostra as métricas finais, sem misturar linhas de média com linhas de modelo.

Modelo	MAE	RMSE	R ²	MAPE	Viés médio
K-Means (Clusterização)	R\$ 617,08	R\$ 803,17	0,689	26,19%	10,42%
Regressão Linear	R\$ 695,91	R\$ 893,20	0,615	30,13%	12,51%
Kernel Ridge	R\$ 572,83	R\$ 753,18	0,726	23,86%	7,90%
Random Forest (IA)	R\$ 496,95	R\$ 647,89	0,797	20,77%	6,86%

Tabela 5 - Métricas preditivas no holdout comum de 268 clientes.




Figura 2 - Comparação de RMSE e R^2 no holdout.

O Random Forest apresentou o menor RMSE e o maior R^2 no holdout. Portanto, para novos clientes, ele é o melhor preditor entre os modelos comparados. O Kernel Ridge, por sua vez, manteve melhor desempenho que K-Means e Regressão Linear, além de possuir formulação matemática mais direta para auditoria do que uma floresta de árvores.

4.4 Resultado contraintuitivo: K-Means acima da Regressão Linear

A Regressão Linear apresentou RMSE superior ao K-Means no holdout. Esse resultado não implica que clusterização seja, em geral, melhor que regressão supervisionada para previsão. A interpretação mais plausível é que o OLS simples ficou mal especificado para este conjunto: há cauda à direita em despesas, efeitos não lineares e interações não explicitadas. O K-Means, embora grosseiro, agrupa clientes por proximidade de perfil e pode capturar parcialmente combinações de idade, IMC e filhos que o modelo linear força em um único coeficiente médio.

Esse achado é cientificamente útil porque mostra o risco de usar um baseline linear apenas por interpretabilidade. Quando a distribuição do alvo é assimétrica e a resposta varia localmente no espaço de atributos, segmentação pode superar uma regressão linear mal especificada, ainda que continue inferior a modelos não lineares ajustados diretamente para perda preditiva.

4.5 Workflow gerado por IA

O termo *vibe coding*, cunhado por Karpathy em 2025, descreve o paradigma em que o desenvolvedor descreve o objetivo em linguagem natural e um modelo de linguagem escreve todo o código — incluindo a escolha do algoritmo e o ajuste de hiperparâmetros — com pouca ou nenhuma revisão técnica humana. O benchmark de IA deste estudo seguiu exatamente esse procedimento: o workflow foi gerado por *vibe coding* na ferramenta Claude Code, da Anthropic, utilizando o modelo Opus 4.7. Solicitou-se, em linguagem natural, um método para prever as despesas de futuros clientes, sem orientar a abordagem estatística e sem revisar o código gerado.

O prompt enviado ao Claude Code reproduz a fala de um gestor sem formação estatística e foi mantido deliberadamente livre de qualquer orientação técnica:

Sou o gestor de uma empresa de plano de saúde. Estou te passando o arquivo "clientes_atuais.csv" onde age = idade do cliente; gender = sexo do cliente; bmi = imc do cliente; children = número de filhos do cliente; region = onde o cliente mora; expenses = o gasto mensal do cliente; premium = o quanto estamos cobrando atualmente. Eu quero saber qual valor cobrar dos próximos clientes (premium). Para isso, primeiramente eu preciso prever qual será o provável valor de "expenses" dos novos clientes. Como eu calculo o provável valor de "expenses" dos novos clientes diante dos valores ("age, gender, bmi, children, region") que obtiver dos novos clientes? Eu quero o melhor valor de predição possível.

A base de dados fornecida ao Claude Code foi exatamente a mesma utilizada pelos demais modelos: os 80% de clientes do conjunto de treinamento descritos na Seção 3.1. Nenhuma informação do conjunto de teste foi exposta à ferramenta durante a construção do modelo. Concluído o workflow, o Random Forest resultante foi aplicado aos mesmos 20% de clientes do conjunto de teste — o holdout de 268 clientes — para que sua eficácia pudesse ser comparada, em igualdade de condições, com a dos modelos selecionados pelo protocolo formal, como já apresentado nas Seções 4.1 a 4.3.

O workflow de IA comparou cinco algoritmos com validação cruzada e tuning por GridSearchCV, selecionando um Random Forest com 300 árvores, profundidade máxima 8, fração de atributos 0,5 e mínimo de 5 amostras para divisão. O próprio workflow estimou RMSE interno de R\$ 546,19; no holdout real, o RMSE foi R\$ 647,89. A diferença representa otimismo de validação interna, mas não anula o resultado principal: no holdout comum, o Random Forest venceu em acurácia.

A implicação é dupla. A IA foi competente para encontrar um modelo forte, compatível com a literatura que destaca ensembles de árvores como candidatos robustos em muitos problemas tabulares. Entretanto, ela não entregou automaticamente uma discussão sobre diagnóstico residual, separação entre novos clientes e clientes atuais, churn, governança ou política de reajuste.

4.6 Churn ao aplicar preços derivados de modelos

A despesa estimada por cada modelo é convertida em preço pela fórmula de margem de 25% apresentada na Seção 3.3. Para avaliar o efeito sobre a carteira atual, calcula-se, para cada cliente, o aumento percentual do prêmio — a diferença entre o prêmio sugerido pelo modelo e o prêmio atualmente cobrado, dividida pelo prêmio atual. Esse aumento alimenta a função de churn de Souza (2025), também apresentada na Seção 3.3, que devolve a probabilidade estimada de cancelamento do cliente: quanto maior o reajuste, maior a chance de churn, com um salto adicional acima de +20% de reajuste por efeito da descontinuidade regulatória. A Tabela 6 detalha esse cálculo para uma amostra de clientes: para cada modelo, mostra o prêmio sugerido (despesa estimada dividida pelo fator $1 - 0,25$), o aumento percentual implícito sobre o prêmio atual e a chance de churn resultante. Cabe registrar que a comparação com o K-Means é justa: embora a clusterização adote margens-alvo diferenciadas por cluster, a média dessas margens equivale a aproximadamente 25%, alinhando-a aos demais modelos.

Cliente	Prêmio atual	K-Means (Clusterização)			Regressão Linear			Kernel Ridge			Random Forest		
		Prêmio sug.	Aumento	Churn	Prêmio sug.	Aumento	Churn	Prêmio sug.	Aumento	Churn	Prêmio sug.	Aumento	Churn
1	R\$ 1.944,92	R\$ 2.525,30	29,8%	64,6%	R\$ 2.473,85	27,2%	58,0%	R\$ 2.447,23	25,8%	54,6%	R\$ 2.533,83	30,3%	65,7%
2	R\$ 5.322,85	R\$ 6.284,35	18,1%	23,1%	R\$ 6.065,66	14,0%	19,0%	R\$ 6.479,92	21,7%	44,3%	R\$ 6.178,72	16,1%	21,1%
3	R\$ 4.913,83	R\$ 6.284,35	27,9%	59,7%	R\$ 5.994,16	22,0%	45,0%	R\$ 6.638,73	35,1%	77,8%	R\$ 6.437,49	31,0%	67,5%
4	R\$ 4.420,46	R\$ 2.996,78	-32,2%	0,0%	R\$ 4.047,10	-8,4%	0,0%	R\$ 3.354,91	-24,1%	0,0%	R\$ 3.042,00	-31,2%	0,0%
5	R\$ 1.662,99	R\$ 2.525,30	51,9%	100,0%	R\$ 2.079,04	25,0%	52,5%	R\$ 2.281,68	37,2%	83,0%	R\$ 2.446,56	47,1%	100,0%
6	R\$ 3.426,41	R\$ 3.273,44	-4,5%	0,5%	R\$ 2.481,12	-27,6%	0,0%	R\$ 2.328,17	-32,1%	0,0%	R\$ 2.719,79	-20,6%	0,0%
7	R\$ 3.191,90	R\$ 2.996,78	-6,1%	0,0%	R\$ 4.699,42	47,2%	100,0%	R\$ 4.193,59	31,4%	68,5%	R\$ 2.961,08	-7,2%	0,0%
8	R\$ 5.284,74	R\$ 6.284,35	18,9%	23,9%	R\$ 5.777,91	9,3%	14,3%	R\$ 6.278,12	18,8%	23,8%	R\$ 5.982,31	13,2%	18,2%

Tabela 6 - Prêmio sugerido por cada modelo, aumento percentual implícito sobre o prêmio atual e chance de churn do cliente, para uma amostra de 8 dos 268 clientes do holdout.

Os preços assim derivados são submetidos à função de churn para classificar cada cliente como retido ou perdido. Adotou-se o limiar de 50%: um cliente é contabilizado como perdido quando sua probabilidade estimada de cancelamento atinge ou supera 50%. Esse valor não é arbitrário — corresponde ao ponto de decisão de erro mínimo (limiar de Bayes) para um desfecho binário sob custos simétricos: ao classificar cada cliente pelo desfecho individualmente mais provável, minimiza-se o número esperado de classificações incorretas. Limiares mais baixos seriam excessivamente conservadores, pois contariam como perdidos clientes cuja probabilidade de permanência ainda supera a de saída; limiares mais altos seriam excessivamente otimistas. Uma alternativa ainda mais rigorosa seria a formulação por valor esperado, que pondera o lucro de cada cliente pela probabilidade de retenção em vez de aplicar um corte rígido; adotou-se o limiar de 50% por coerência com a convenção operacional do notebook. Em qualquer caso, o mesmo limiar é aplicado a todos os modelos, de modo que a comparação entre eles permanece justa.

Quando esses prêmios sugeridos são aplicados como se fossem reajustes sobre a carteira atual, todos os modelos geram perdas relevantes por churn. A Tabela 7 e a Figura 3 mostram que o Kernel Ridge gerou menos clientes acima do limiar de 50% de churn do que o Random Forest, mas essa comparação pertence ao cenário de carteira atual, não ao problema de novos clientes.

Modelo	Clientes com churn $\geq 50\%$	% da base	Perda de lucro
K-Means (Clusterização)	148	55,2%	R\$ 227.294,00
Regressão Linear	140	52,2%	R\$ 229.115,84
Kernel Ridge	121	45,1%	R\$ 197.987,34
Random Forest (IA)	133	49,6%	R\$ 201.502,68

Tabela 7 - Churn simulado ao aplicar preços derivados dos modelos à carteira atual.




Figura 3 - Churn e perda de lucro por modelo na simulação de reajuste.

Esse resultado reforça a tese do artigo: melhor previsão de despesa não equivale automaticamente à melhor política de reajuste. Para clientes atuais, a empresa já conhece o prêmio vigente e a despesa realizada; o problema operacional passa a ser definir quanto reajustar sem ultrapassar uma tolerância de churn.

4.7 Política específica para clientes atuais

A carteira atual exige tratamento distinto. Aplicar diretamente os preços dos modelos preditivos aos clientes existentes reduziria o lucro abaixo do patamar atual, como mostrou a Seção 4.6. A razão é conceitual: para um cliente que já está na base, a empresa não precisa estimar a despesa — ela já a observa —, tampouco precisa estimar o prêmio, pois já o cobra. O problema deixa de ser previsão e passa a ser decisão de reajuste sob restrição de churn. Por isso, para esse cenário, adota-se uma abordagem sem modelo preditivo.

O procedimento tem três passos. Primeiro, fixa-se um alvo de churn considerado aceitável. Segundo, inverte-se a função de churn de Souza (2025) para descobrir qual reajuste percentual produz exatamente aquele churn, traduzindo-o em um novo valor a cobrar de cada cliente. Terceiro, aplicam-se duas salvaguardas: nunca reduzir o prêmio de um cliente abaixo do valor já cobrado; e nunca cobrar abaixo de um piso de 9,52% de margem sobre a despesa ($\text{expenses} \times 1,0952$). Clientes estruturalmente deficitários, para os quais mesmo esse piso eleva o churn acima de 50%, são tratados como perdidos — manter um cliente que dá prejuízo destrói valor mais rápido do que perdê-lo.

Para tornar esse procedimento concreto, a Tabela 8 o aplica ao alvo recomendado de 15% de churn, detalhando cliente a cliente cada etapa. As primeiras colunas descrevem a situação atual de cada cliente — despesa, prêmio cobrado, margem e lucro — e as colunas seguintes mostram o valor a cobrar obtido pela inversão da função de churn, o aumento percentual implícito e o lucro considerando o churn resultante; são exibidas seis linhas de exemplo e a última agrega os 268 clientes do holdout. Com o alvo de 15%, o reajuste uniforme implícito é de apenas 10,00% e o lucro considerando churn sobe de R\$ 69.695,36 para R\$ 153.784,46 — um ganho de R\$ 84.089,10, com a chance de churn de cada cliente mantida em 15%.

Cliente	Despesa (R\$)	Prêmio atual (R\$)	Margem atual (%)	Lucro atual (R\$)	Valor a cobrar (R\$)	Aumento (%)	Chance de churn (%)	Lucro c/ churn (R\$)
1	R\$ 1.653,18	R\$ 1.944,92	15,0%	R\$ 291,74	R\$ 2.139,41	10,0%	15,0%	R\$ 486,23
2	R\$ 5.589,00	R\$ 5.322,85	-5,0%	R\$ -266,15	R\$ 5.855,14	10,0%	15,0%	R\$ 266,14
3	R\$ 5.159,52	R\$ 4.913,83	-5,0%	R\$ -245,69	R\$ 5.405,21	10,0%	15,0%	R\$ 245,69
4	R\$ 3.315,35	R\$ 4.420,46	25,0%	R\$ 1.105,11	R\$ 4.862,51	10,0%	15,0%	R\$ 1.547,16
5	R\$ 1.413,54	R\$ 1.662,99	15,0%	R\$ 249,45	R\$ 1.829,29	10,0%	15,0%	R\$ 415,75
6	R\$ 2.569,80	R\$ 3.426,41	25,0%	R\$ 856,61	R\$ 3.769,05	10,0%	15,0%	R\$ 1.199,25
Total	R\$ 771.195,59	R\$ 840.890,95	8,3%	R\$ 69.695,36	R\$ 924.980,05	—	—	R\$ 153.784,46

Tabela 8 - Detalhe por cliente da política de reajuste no alvo recomendado de 15% de churn, para uma amostra de 6 dos 268 clientes do holdout; a última linha agrega toda a base.

A Tabela 9 repete o exercício no teto teórico de 49,9% de churn. Cobra-se sensivelmente mais de cada cliente — aumento implícito de 23,96% — e o lucro agregado sobe para R\$ 271.172,83, mas a chance de churn de cada cliente fica próxima de 50%, situação em que qualquer erro de calibração o empurra para o cancelamento. O contraste entre as duas tabelas evidencia o trade-off central da carteira: aceitar mais churn rende mais, até o limite em que a base começa a se desfazer.

Cliente	Despesa (R\$)	Prêmio atual (R\$)	Margem atual (%)	Lucro atual (R\$)	Valor a cobrar (R\$)	Aumento (%)	Chance de churn (%)	Lucro c/ churn (R\$)
1	R\$ 1.653,18	R\$ 1.944,92	15,0%	R\$ 291,74	R\$ 2.410,92	24,0%	49,9%	R\$ 757,74
2	R\$ 5.589,00	R\$ 5.322,85	-5,0%	R\$ -266,15	R\$ 6.598,20	24,0%	49,9%	R\$ 1.009,20
3	R\$ 5.159,52	R\$ 4.913,83	-5,0%	R\$ -245,69	R\$ 6.091,18	24,0%	49,9%	R\$ 931,66
4	R\$ 3.315,35	R\$ 4.420,46	25,0%	R\$ 1.105,11	R\$ 5.479,60	24,0%	49,9%	R\$ 2.164,25
5	R\$ 1.413,54	R\$ 1.662,99	15,0%	R\$ 249,45	R\$ 2.061,44	24,0%	49,9%	R\$ 647,90
6	R\$ 2.569,80	R\$ 3.426,41	25,0%	R\$ 856,61	R\$ 4.247,38	24,0%	49,9%	R\$ 1.677,58
Total	R\$ 771.195,59	R\$ 840.890,95	8,3%	R\$ 69.695,36	R\$ 1.042.368,42	—	—	R\$ 271.172,83

Tabela 9 - Detalhe por cliente no teto teórico de 49,9% de churn, para a mesma amostra de 6 clientes; a última linha agrega toda a base.

As Tabelas 8 e 9 são apenas dois pontos de uma curva contínua. A Figura 4 percorre todos os alvos de churn possíveis: o lucro considerando churn cresce à medida que se aceita mais cancelamento — cobra-se mais, ganha-se mais — até o teto de 49,9%, que elevaria o lucro de R\$ 69.695,36 para R\$ 271.172,83. A curva apresenta um patamar entre cerca de 24,9% e 40% de churn: por causa da descontinuidade regulatória da função de churn em +20% de reajuste, esses níveis intermediários são inalcançáveis e o lucro não varia nessa faixa.




Figura 4 - Lucro ajustado por churn para a carteira atual.

O teto de 49,9%, contudo, é um limite, não uma meta: depende da hipótese de que a calibração de churn seja exata para todos os clientes e não deixa margem de segurança gerencial. Por isso o alvo recomendado é o de 15% de churn, da Tabela 8, valor ancorado na literatura. Souza (2025) identifica uma descontinuidade regulatória em +20% de reajuste — o patamar da ANS que aciona o direito do beneficiário de trocar de operadora —, de modo que manter o churn na região linear segura exige reajustes bem abaixo desse ponto. Esse alvo é ainda corroborado por benchmarks de mercado de saúde suplementar, que apontam retenção anual em torno de 83%, equivalente a 15-17% de churn. O reajuste de 10,00% da Tabela 8 permanece confortavelmente abaixo da descontinuidade, preservando margem para erros de calibração e para reajustes futuros.

Conhecido o detalhamento das Tabelas 8 e 9 e a curva da Figura 4, a Tabela 10 resume os dois cenários de decisão — o alvo recomendado de 15% e o teto teórico de 49,9% — frente à situação atual da carteira.

Chance de Churn do cliente	Aumento implícito	Churn $\geq 50\%$	Lucro considerando chances de Churn	Ganho vs. atual
Atual	-	-	R\$ 69.695,36	-
Alvo recomendado 15%	10,00%	0	R\$ 153.784,46	R\$ 84.089,10
Teto teórico 49,9%	23,96%	0	R\$ 271.172,83	R\$ 201.477,47

Tabela 10 - Política de reajuste para clientes atuais baseada em alvo de churn.

5 Discussão

O estudo mostra que a avaliação de modelos de pricing deve separar três camadas. A primeira é estatística: qual modelo prevê melhor despesas no holdout? Nessa camada, o Random Forest gerado por IA foi superior. A segunda é metodológica: qual modelo é mais defensável dentro de um protocolo explícito de escolha estrutural? Nessa camada, Kernel Ridge representa a melhor alternativa formal encontrada antes do benchmark de IA. A terceira é gerencial: qual política de preço maximiza valor sem destruir retenção? Nessa camada, a carteira atual exige regra própria de churn.

A principal advertência para gestores é que o sucesso de um modelo em novos clientes não autoriza sua aplicação direta a clientes atuais. Se uma empresa contrata um estudo para prever despesas futuras, o analista agrega valor ao mostrar também o que fazer com a carteira existente. Deixar clientes atuais sem ajuste pode representar perda de dinheiro; por outro lado, reajustar todos com base em despesa prevista pode provocar churn. A solução é tratar a carteira atual como problema de otimização sob restrição de cancelamento.

O resultado também ilustra um papel realista para IA generativa em ciência de dados. Ela pode acelerar exploração, seleção de modelos e tuning. Ainda assim, o valor profissional do cientista de dados permanece na validação, na definição correta do problema, na crítica das métricas, na tradução do modelo para decisão econômica e na governança do uso.

6 Conclusão

Este artigo apresentou uma modelagem matemática abrangente para recomendação de preços em seguro saúde, orientada por princípios de Identificação de Sistemas e comparada a um workflow gerado por IA. O estudo demonstrou que, para novos clientes, o Random Forest gerado por IA obteve a melhor acurácia no holdout. Demonstrou também que Kernel Ridge foi a melhor alternativa formal antes desse benchmark e que K-Means superar Regressão Linear é um alerta sobre má especificação linear em bases assimétricas e não lineares.

A conclusão prática é que a empresa deve operar com duas trilhas: usar o melhor modelo validado para precificar novos clientes e usar uma regra de reajuste controlada por churn para clientes atuais. A contribuição científica está no framework, não apenas no ranking de algoritmos: previsão, preço, churn e lucro devem ser avaliados conjuntamente.

7 Limitações

As principais limitações são: uso de base pública de tamanho moderado; ausência de variáveis clínicas detalhadas; função de churn parametrizada para simulação e não estimada diretamente nesta base; ausência de validação temporal; e comparação com um único workflow de IA. Além disso, o estudo não substitui validação atuarial, regulatória e ética para uso real em seguradoras.

Referências

AGUIRRE, L. A. Introdução à Identificação de Sistemas: técnicas lineares e não lineares aplicadas a sistemas reais. 4. ed. Belo Horizonte: Editora UFMG, 2014.

AAS, K. et al. Insurance analytics: prediction, explainability, and fairness. *Annals of Actuarial Science*, 2024. Disponível em: <https://www.cambridge.org/core/journals/annals-of-actuarial-science/article/insurance-analytics-prediction-explainability-and-fairness/CF5EDDEA60798783CEFD5FBE6A51A8FF>.

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, p. 5-32, 2001. Disponível em: <https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf>.

DIEBOLD, F. X.; MARIANO, R. S. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, v. 13, n. 3, p. 253-263, 1995. DOI: 10.1080/07350015.1995.10524599.

FERNÁNDEZ-DELGADO, M. et al. Do we need hundreds of classifiers to solve real world classification problems? *Journal of Machine Learning Research*, v. 15, n. 90, p. 3133-3181, 2014. Disponível em: <https://jmlr.csail.mit.edu/beta/papers/v15/delgado14a.html>.

GU, Y. et al. Large Language Models for Constructing and Optimizing Machine Learning Workflows: A Survey. *arXiv:2411.10478*, 2024. DOI: 10.48550/arXiv.2411.10478.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning*. 2. ed. New York: Springer, 2009.

JAMES, G. et al. *An Introduction to Statistical Learning*. New York: Springer, 2013.

JANSEN, J. A. et al. Leveraging large language models for data analysis automation. *PLOS ONE*, v. 20, n. 2, e0317084, 2025. DOI: 10.1371/journal.pone.0317084.

KAPSE, M. et al. Customization of health insurance premiums using machine learning and explainable AI. *International Journal of Information Management Data Insights*, v. 5, n. 1, 100328, 2025. DOI: 10.1016/j.jjime.2025.100328.

KSHIRSAGAR, R. et al. Accurate and Interpretable Machine Learning for Transparent Pricing of Health Insurance Plans. *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 35, n. 17, p. 15127-15136, 2021. DOI: 10.1609/aaai.v35i17.17776.

LJUNG, L. *System Identification: Theory for the User*. 2. ed. Upper Saddle River: Prentice Hall, 1999.

ORJI, U.; UKWANDU, E. Machine learning for an explainable cost prediction of medical insurance. *Machine Learning with Applications*, v. 15, 100516, 2024. DOI: 10.1016/j.mlwa.2023.100516.

SCHÖLKOPF, B.; SMOLA, A. J. *Learning with Kernels*. Cambridge: MIT Press, 2002.

SOUZA, A. P. et al. Effect of age-related premium readjustment on health insurance cancellation in Brazil: regression discontinuity approach. *Health Economics*, v. 34, n. 1, p. 3-17, 2025. DOI: 10.1002/hec.4898.

ZENG, Q. et al. AIRepr: An Analyst-Inspector Framework for Evaluating Reproducibility of LLMs in Data Science. arXiv:2502.16395, 2025. DOI: 10.48550/arXiv.2502.16395.